

SISTEM PENDETEKSI GENUS GULMA PADA TANAMAN JAGUNG MENGGUNAKAN ALGORITMA *SINGLE SHOT DETECTOR*

Ade Agustian Saputra¹, Boko Susilo², Mochammad Yusa³, Uswatun Nurjanah⁴

^{1,2,3} Program Studi Informatika, Fakultas Teknik, Universitas Bengkulu

⁴ Program Studi Agroteknologi, Fakultas Pertanian, Universitas Bengkulu

Jl. WR. Supratman Kandang Limun Bengkulu 38371 INDONESIA

(telp: 0736-341022; fax: 0736-341022)

¹adeas587@gmail.com, ²bokosusilo@unib.ac.id, ³mochammad.yusa@unib.ac.id, ⁴uswatun.nurjannah@gmail.com

Abstrak

Tanaman jagung (*Zea mays L*) merupakan tanaman pangan penghasil karbohidrat potensial kedua di Indonesia setelah beras. Provinsi Bengkulu merupakan provinsi yang sebagian besar wilayahnya merupakan kawasan hutan lindung dan hutan rakyat. Perkebunan jagung mengalami gangguan, antara lain disebabkan oleh gulma. Gulma merupakan tumbuhan liar yang sering muncul di pekarangan rumah dan pertanian masyarakat. Penelitian ini hanya diambil empat jenis gulma yang sering muncul di perkebunan jagung yaitu *Ageratum sp*, *Commelina sp*, *Eleusine sp*, dan *Sacciolepis sp*. Penelitian ini dibangun sebuah model identifikasi genus gulma dengan memanfaatkan algoritma *Single Shot Detector (SSD)*. *Single Shot Detector* merupakan sebuah model yang dapat mendeteksi atau mengenali objek pada suatu gambar. Penelitian ini menggunakan 800 dataset training untuk melatih sistem *Deep Learning* dan 150 Dataset testing untuk validasi dan evaluasi terhadap model yang dihasilkan. Dengan nilai *threshold IoU* dan *minimum confidence @0.80* tingkat akurasi yang didapatkan pada penelitian ini sebesar **62.44%**.

Kata kunci: *Deep Learning*, Gulma, Jagung, *Single Shot Detector (SSD)*

Abstract: Corn (*Zea mays L*) is the second potential carbohydrate-producing food crop in Indonesia. Bengkulu Province is a province where most of its territory is protected forest area and community forest. Corn plantations are experiencing disturbances, among others caused by weeds. Weeds are lying plants that often appear in people's yards and farms. This study only took four types of weeds that often appear in corn plantations, namely *Ageratum sp*, *Commelina sp*, *Eleusine sp*, and *Sacciolepis sp*. This study builds a model of the weed genus by utilizing the *Single Shot Detector (SSD)* algorithm. *Single Shot Detector* is a model that can detect or recognize objects in an image. This study uses 800 training datasets to train the *Deep Learning* system and 150 testing datasets for validation and evaluation of the resulting model. With the *IoU* threshold value and *minimum confidence @ 0.80* the accuracy obtained in this study was **62.44%**.

Keywords: *Deep Learning*, Gulma, Corn, *Single Shot Detector (SSD)*

1. PENDAHULUAN

Tanaman jagung (*Zea mays L*) merupakan tanaman pangan penghasil karbohidrat potensial kedua di Indonesia setelah beras. Tanaman jagung merupakan golongan *Spermatophyta*, kelas *Monocotyledone*, ordo *Graminae*, dan familia *Graminaceae* serta genus *Zea* atau *Zea Mays* (bahasa latin). Sekarang ini jagung telah menjadi komoditas perdagangan dunia, semua negara berlomba-lomba meningkatkan produksinya untuk memenuhi permintaan industrinya (Sastroutomo, 1990).

Provinsi Bengkulu merupakan provinsi yang sebagian besar wilayahnya merupakan kawasan hutan lindung dan hutan rakyat. Mayoritas masyarakat provinsi Bengkulu mencari penghasilan dengan cara bertani. Salah satu daerah penghasil jagung di Bengkulu berada di Kabupaten Bengkulu Utara. Hasil produksi jagung Bengkulu mencapai

72.986/ton dengan luas perkebunan jagung 15.697 hektare (Musriadi, 2014).

Perkebunan jagung mengalami beberapa gangguan, antara lain disebabkan oleh gulma. Gulma merupakan tumbuhan yang mengganggu tanaman jagung sehingga para petani berusaha untuk mengendalikannya. Berbagai metode pengendalian gulma dapat diterapkan pada budidaya tanaman jagung, metode tersebut adalah pengendalian kimiawi. Pengendalian kimiawi, yaitu penggunaan herbisida, merupakan metode yang paling banyak digunakan karena tingkat efisiensi dan efektivitas yang tinggi (Mas'ud, 2019).

Gulma pada tanaman jagung juga memiliki beberapa spesies yang sering sekali muncul dan mengganggu tanaman jagung. Spesies merupakan pengelompokkan makhluk hidup yang dipakai dalam klasifikasi biologis pada satu atau beberapa kelompok makhluk hidup dan dapat saling membuahi satu sama lain sehingga menghasilkan keturunan yang subur. Pada penelitian ini hanya diambil empat jenis gulma yang sering muncul di setiap perkebunan jagung yaitu *Ageratum sp*, *Commelina sp*, *Eleusine sp*, dan *Sacciolepis sp* (Saptasari & Murni, 2012).

Gulma pada tanaman jagung tanpa olah tanah dikendalikan dengan herbisida. Sebelum jagung ditanam, herbisida disemprotkan untuk mematikan gulma yang tumbuh di area pertanian. Setelah jagung tumbuh, gulma masih perlu dikendalikan untuk melindungi tanaman. Pengendalian dapat dilakukan dengan cara penyiangan dengan tangan, penggunaan alat mekanis, dan penyemprotan herbisida (Tabri & Fahdiana, 2017). Berkembangnya *artificial intelligence (AI)* atau yang disebut dengan kecerdasan buatan di dunia saat ini, membuat para petani dapat mendapatkan keuntungan yang banyak

serta tidak perlu mencari buruh untuk melakukan penyiangan. “Robot Pembersih Tanaman Gulma Padi Otomatis” adalah sebuah robot *autonomous* yang dapat mencabut sekaligus menghancurkan tanaman hama yang ada di sekitar tanaman padi menggunakan *mikrokontroler arduino* serta beberapa motor DC sebagai penggerak dan juga menggunakan beberapa sensor yang berfungsi untuk memudahkan pekerjaan para petani (Muhazzab, Soetedjo, & Ashari, 2019). Penelitian-penelitian yang sudah menggunakan kecerdasan buatan sebagai pengendalian gulma terhadap tanaman budidaya, seperti “pengenalan pola daun untuk membedakan tanaman padi dan gulma menggunakan metode *Principal Components Analysis (PCA)* Dan *Extreme Learning Machine (ELM)*”. (Izzuddin & Wahyudi, 2020) menyatakan bahwa pada penelitian pengenalan pola daun padi dan gulma dapat diambil kesimpulan bahwa Implementasi *PCA* dan *ELM* mampu membedakan tanaman gulma dengan padi. Penelitian kedua seperti: “mendeteksi gulma pertengahan hingga akhir musim menggunakan metode *Region based Convolutional Neural Networks (R-CNN)* dan *Single Shot Detector (SSD)*” . (Sivakumar, et al., 2020) menyatakan bahwa deteksi gulma pertengahan hingga akhir musim bahwa performa *Region based Convolutional Neural Networks (R-CNN)* dalam mendeteksi gulma lebih akurat dalam mendeteksi objek sedangkan metode *Single Shot Detector (SSD)* hasil mendeteksi objek hanya menggunakan *bounding boxes*.

Single Shot Detector umumnya mempunyai kecepatan deteksi diatas algoritma lainnya sedangkan *Faster R-CNN* merupakan Salah satu algoritma yang mempunyai tingkat akurasi dan kecepatan deteksi yang hampir seimbang dengan *Single Shot Detector*. Penelitian ini akan melakukan identifikasi gulma tanaman jagung yang

menggunakan metode *Single Shot Detector (SSD)*. *Single Shot Detector* menerapkan fitur *Bounding boxes* untuk menentukan lokasi objek yang dideteksi yang memiliki komputasi dan nilai kecepatan deteksi yang lebih tinggi dibanding metode lainnya. Dengan *SSD* proses dapat dipercepat karena menghilangkan kebutuhan jaringan proposal wilayah / *region proposal network*. Untuk mengembalikan penurunan dari akurasi, *SSD* menerapkan beberapa peningkatan berupa *multi-scale features maps* dan *default boxes*, *SSD* mencapai proses yang lebih cepat dan mengalahkan akurasi *Faster R-CNN*. *Single shot Detector* dengan *Mobilenet* menghasilkan waktu tercepat dibanding dengan *Faster R-CNN* dan *R-FCN* dengan akurasi 19,3 *mAP* (Huang, et al., 2017). Selain fitur lingkaran dan elips, deteksi objek dalam citra dapat memberikan *output* berupa *bounding box* dengan aspek rasio dan skala yang berbeda untuk setiap lokasi *feature map*.

Berdasarkan uraian diatas maka penulis membuat sistem deteksi gulma pada tanaman jagung yang Tujuan penelitian ini yaitu menghasilkan model baru untuk deteksi gulma pada tanaman jagung (*zea mays*) dan juga mengetahui akurasi *Single Shot Detector (SSD)* dalam mendeteksi gulma.

2. MATERI PENELITIAN

2.1 Gulma

Gulma merupakan tumbuhan liar yang sering muncul di pekarangan rumah dan pertanian masyarakat. Keberadaan gulma pada tanaman budidaya dapat menimbulkan kerugian kualitas produksi. Kerugian yang ditimbulkan oleh gulma adalah penurunan hasil pertanian, persaingan dalam perolehan air, unsur hara, tempat hidup, yang akhirnya menyebabkan terganggunya tanaman (Ahmad & Junaedi, 2006).

Di bawah ini merupakan jenis-jenis gulma:

1. *Commelina sp*



Gambar 1. *Commelina sp*

Gambar 1 merupakan gulma *Commelina sp* yang dikenal dengan nama gewor yang tumbuh menjalar, umumnya ditemukan di tempat lembab pada daerah tropis dan sub tropis, juga termasuk gulma yang hidup liar di pekarangan-pekarangan rumah dan dilahan pertanian (Hartono, 2009).

2. *Ageratum sp*



Gambar 2. *Ageratum sp*

Gambar 2 merupakan gulma *Ageratum sp* yang dikenal dengan nama bandotan adalah tumbuhan liar yang tumbuh di sekitar kebun dan berpotensi

menjadi gulma apabila populasinya tinggi. Tumbuhan ini sering ditemukan di perkarangan rumah, kebun, sawah, dan tepi jalan. Tumbuhan ini dapat berkembang biak dengan baik di wilayah tropika dan sub tropika (Indra, 2017).

3. *Sacciolepis sp*



Gambar 3. *Sacciolepis sp*

Gambar 3 merupakan gulma *Sacciolepis sp*, merupakan golongan *familia poaceae* yang sering tumbuh dipekarangan pertanian, merupakan gulma tropis yang daunnya hampir mirip dengan padi (Arisandi, Dharmono, & Muchyar, 2015).

4. *Eleusine sp*



Gambar 4. *Eleusine sp*

Gambar 4 merupakan gulma *Eleusine sp* yang dikenal dengan rumput belulang merupakan gulma yang sering muncul di setiap pertanian seperti persawahan dan perkebunan (Razak, 2018).

2.2 Jagung

Jagung (*Zea mays L*) merupakan tanaman pangan penghasil karbohidrat potensial kedua di Indonesia setelah beras. Tanaman jagung juga memiliki golongan *spermatophyta*, kelas *monocotyledone*, *ordo gramineae*, dan *familia graminaceae* serta genus *zea* atau *zea zays* (bahasa latin) (Sastroutomo, 1990). Rejang Lebong merupakan salah satu kabupaten yang berada di provinsi Bengkulu yang merupakan salah satu daerah penghasil jagung. Hasil produksi jagung di kabupaten Rejang Lebong pada tahun 2013-2015 yaitu sebesar 62.321 ton.

2.3 Deep Learning


Deep Learning adalah *subfield Artificial Intelligence (AI)* itu meniru karya otak manusia dalam memproses data dan menghasilkan pola untuk digunakan dalam pengambilan keputusan. Pembelajaran yang mendalam adalah bagian dari pembelajaran mesin dalam kecerdasan buatan itu memiliki jaringan keterampilan belajar dari data yang ada tidak berlabel atau tidak terstruktur (A, et al., 2019).

2.4 Single Shot Detector

Single Shot Detector merupakan sebuah model yang dapat mendeteksi atau mengenali objek pada suatu gambar. Sebagai salah satu model deep learning yang memiliki kemampuan yang sangat baik untuk mengklasifikasikan data dengan struktur tiga dimensi seperti video *real-*

time. Model SSD dengan lapisan MobileNet dapat bekerja dalam sedikit komputasi (Thohar & Adhitama, 2019).

penelitian yang dilakukan dengan tujuan menerapkan, menguji, dan mengevaluasi kemampuan suatu teori yang diterapkan dalam



Gambar 5. Arsitektur SSD (Bozkurt, 2019).

Single Shot: Lokalisasi dan klasifikasi objek dilakukan dalam jaringan forward pass tunggal
Multibox: Teknik Regresi Kotak Pembatas
Detektor: Mengklasifikasi objek yang terdeteksi

Gambar 5 merupakan Arsitektur SSD dibangun berdasarkan arsitektur VGG-16. Tapi di sini ada sedikit perubahan pada VGG-16, menggunakan set lapisan konvolusional tambahan dari lapisan Conv6 dan seterusnya, bukan lapisan yang terhubung sepenuhnya. Alasan menggunakan VGG-16 sebagai jaringan dasar adalah klasifikasi gambar berkualitas tinggi dan pembelajaran transfer untuk meningkatkan hasil. Dengan menggunakan lapisan konvolusional tambahan, dapat mengekstrak fitur pada berbagai skala dan secara bertahap mengurangi ukuran pada setiap lapisan berikutnya (Bozkurt, 2019)

3. METODE PENELITIAN

3.1 Jenis Penelitian

Jenis penelitian yang dilakukan adalah penelitian terapan (*applied research*) yaitu

memecahkan masalah-masalah. Penelitian ini bertujuan untuk menerapkan model *Single Shot Detector* (SSD) untuk melakukan identifikasi gulma yang tumbuh disekitar tanaman budidaya. Untuk tanaman budidaya yang dimaksud adalah tanaman jagung.

3.2 Desain Penelitian

Desain penelitian yaitu strategi yang akan di teliti untuk mengintegrasikan secara menyeluruh komponen riset dengan cara yang logis dan sistematis untuk membahas dan menganalisis apa yang akan menjadi fokus penelitian.

Gambar 6 merupakan flowchart dari penelitian ini:



Gambar 6. Desain proses penelitian

Berikut penjelasan dari diagram alur gambar 6:

1. Mulai mencari data
2. Studi Pustaka ini dilakukan dengan cara mengumpulkan data dari berbagai literatur, seperti buku, jurnal, dan media internet yang berhubungan dengan penelitian yang membahas kriteria gulma pada tanaman Jagung.
3. Studi Lapangan dilakukan dengan cara turun langsung ke perkebunan jagung untuk mengumpulkan data-data berupa foto gulma dan jagung. Yang mana lokasi penelitian nya di kelurahan air bang kecamatan Curup Tengah Kabupaten Rejang Lebong Provinsi Bengkulu.

4. Setelah studi lapangan dilakukan maka akan langsung mengambil dataset berupa foto. setelah foto terkumpul akan langsung verifikasi ke pakar di bidang ilmu gulma, yaitu ibu Dr. Uswatun Nurjanah, Ir. M, yang merupakan salah satu dosen Fakultas Pertanian yang ada di Universitas Bengkulu. Yang mana akan dilakukan evaluasi dan memilih gulma untuk kebutuhan model.

5. Tahap selanjutnya yaitu mengubah data gambar yang tidak sesuai kebutuhan model ke gambar yang sesuai dengan kebutuhan model, untuk kebutuhan deteksi objek yang lebih lanjut agar mendapatkan akurasi dari gulma yang sesuai. Tahap *preproccesing* terdiri dari *resize image*, *augmentasi*, dan *anotasi*.

6. Setelah semua data telah diubah agar sesuai dengan kebutuhan sistem maka akan menjalankan Training data unutm melatih algoritma.

7. Setelah training data dilakukan maka mendapatkan hasil visualisasi gambar yang secara jelas dan efisien melalui grafik *tensorboard*.

8. Tahap selanjutnya setelah mendapatkan hasil grafik *tensorboard* yaitu dilakukan evaluasi matriks model.

9. Setelah mendapatkan hasil visualisasi gambar dan evaluasi matriks model maka mendapatkan hasil deteksi yaitu dilakukan pada 4 kelas gulma yaitu *Ageratum sp.*, *Commelina sp.*, *Eleusine sp.* dan *Sacciolepis sp.*

10. Selesai.

4. HASIL DAN PEMBAHASAN

4.1 Teknik Pengumpulan Data

Data yang di ambil pada penelitian ini yaitu berupa gambar yang diambil langsung di perkebunan

jagung masyarakat. *Dataset* yang telah berhasil dikumpulkan yaitu 1200 foto. Jenis sumber data yang digunakan adalah data primer dan sekunder. Data primer adalah data yang diperoleh langsung dari responden atau objek yang diteliti atau ada hubungannya dengan objek yang diteliti sedangkan data sekunder adalah data yang diperoleh dari sumber yang sudah ada yaitu seperti jurnal, buku, dll

Data diambil di daerah perkebunan masyarakat di kecamatan Curup Tengah Kabupaten Rejang Lebong Provinsi Bengkulu. Pada proses pengumpulan data, ada tiga metode yang digunakan yaitu studi pustaka, Studi Lapangan, dan wawancara. Pengumpulan data-data tersebut dilakukan dengan cara berikut ini:

1. Studi Pustaka

Studi pustaka dilakukan dengan cara mengumpulkan data dari berbagai literatur, seperti buku, jurnal, dan media internet yang berhubungan dengan penelitian yang membahas kriteria gulma pada tanaman Jagung serta implementasi *Single Shot Detector (SSD)*. Studi Pustaka ini termasuk data sekunder dalam penelitian ini.

2. Studi Lapangan

Metode ini dilakukan dengan cara turun langsung ke perkebunan jagung untuk mengumpulkan data-data berupa foto gulma dan jagung.

3. Wawancara

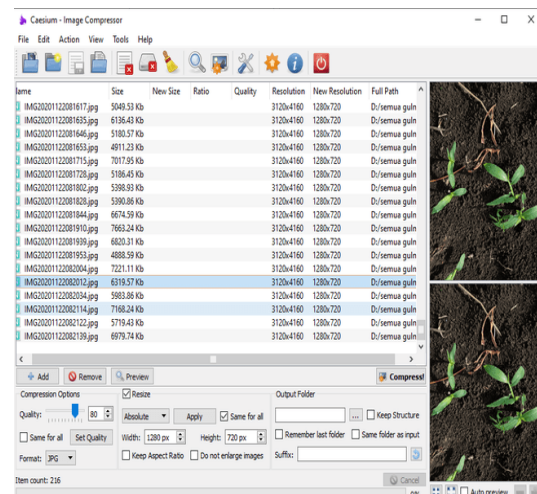
Metode ini dilakukan dengan cara mengumpulkan informasi dari pakar di bidang ilmu gulma, Materi Wawancara yang dilakukan berkaitan erat dengan informasi detail tentang data gulma yang akan menunjang penelitian ini. Hasil yang didapatkan dari wawancara tersebut terdapat 4 jenis gulma yang akan di masukkan

dalam penelitian ini, yaitu: *Ageratum sp.*, *Commelina sp.*, *Eleusine sp.* dan *Sacciolepis sp.*

4.2 Image Preprocessing

1. Resize Image

Resize image berperan untuk menyamaratakan semua gambar pada tingkat ukuran yang sama, yaitu 1280x720p menggunakan aplikasi *Caesium*. Dengan tetap mempertahankan aspek rasio dari gambar asli. Gambr 7 merupakan proses *resize image*:



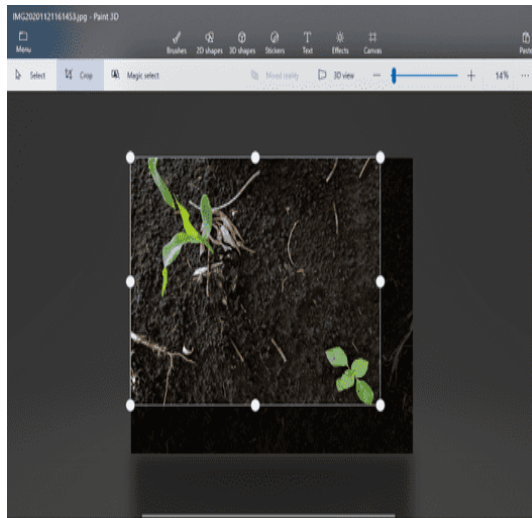
Gambar 7. *Resize image*

Pada Gambar 7 merupakan data yang telah di ambil, dikarenakan ukuran gambar berbeda-beda seperti pada gambar di atas dengan resolution 3120x4160 maka dirubah menjadi 1280x720. Hal ini dilakukan karena rata-rata resolusi minimal foto yang bisa di ambil perangkat kamera saat ini adalah 1280x720. Kenapa dirubah menjadi 1280x720 Untuk meringankan kerja dari *training* data dan meringankan di saat *upload* data ke *google drive*.

2. Augmentasi Gambar

Augmentasi gambar dilakukan secara manual menggunakan aplikasi *Paint 3D* untuk meningkatkan kinerja model. *Augmentasi* yang

dilakukan yaitu *cropping*, *editing*. Gambar 8 merupakan contoh proses augmentasi:



Gambar 8. Proses *cropping* data

Gambar 8 merupakan *Cropping* data untuk menentukan bagian sudut dari suatu gambar seperti memotong, mengambil, mengeluarkan sebagian isi dari gambar guna memperoleh hasil yang diinginkan.



Gambar 9. Sebelum diedit

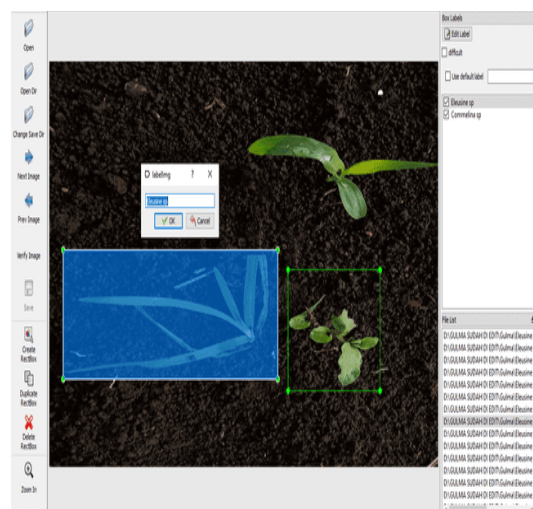


Gambar 10. Setelah di edit

Dari gambar 9 dan 10 merupakan data citra yang diedit agar data citra sesuai dengan kebutuhan model. Dapat dilihat pada tanda panah seperti gambar 10 yaitu menghilangkan objek yang tidak dibutuhkan di penelitian ini.

3. Anotasi

Anotasi dilakukan untuk memberi label pada objek yang terdapat pada gambar. Ini berguna untuk mendapatkan indikasi cepat tentang atribut suatu gambar. Fungsinya untuk mengetahui posisi, bentuk, dan atribut unik objek dalam suatu gambar. Perangkat lunak yang digunakan untuk pelabelan ini yaitu "*Labeling*". Gambar 11 merupakan gambar anotasi:



Gambar 11. Anotasi gambar

Dari gambar 11 Setelah semua gambar sudah selesai di anotasi, semua disimpan kedalam format Pascal VOC, karena labeling menyediakan hanya 2 format yaitu *Pascal VOC* dan *YOLO*. Tipe file dari *Pascal VOC* adalah *XML*, tipe *XML* ini akan diubah kedalam tipe *CSV* agar dapat di generate kedalam format *TensorFlow records*.

4.3 Visualisasi Hasil Training

Untuk dapat memvisualisasikan hasil *training* bisa dilihat dengan grafik pada *tensorboard* yang memvisualisasikan semua pekerjaan pada saat proses *training* dengan grafik *tensorboard* peneliti dapat melihat beberapa grafik seperti *loss* dan *global step*. Berikut gambar dan penjelesan pada masing-masing grafik:


```

10604 06:29:42.377816 140422082593664 basic_session_run_hooks.py:260] loss = 1.4283793, step = 297029 (13.688 sec)
INFO:tensorflow:global_step/sec: 7.47361
10604 06:29:55.756397 140422082593664 basic_session_run_hooks.py:692] global_step/sec: 7.47361
INFO:tensorflow:loss = 1.60664, step = 297929 (13.381 sec)
10604 06:29:55.757890 140422082593664 basic_session_run_hooks.py:260] loss = 1.60664, step = 297929 (13.381 sec)
INFO:tensorflow:global_step/sec: 7.32383
10604 06:30:09.410468 140422082593664 basic_session_run_hooks.py:692] global_step/sec: 7.32383
INFO:tensorflow:loss = 1.2992477, step = 298029 (13.653 sec)
10604 06:30:09.411314 140422082593664 basic_session_run_hooks.py:260] loss = 1.2992477, step = 298029 (13.653 sec)
INFO:tensorflow:global_step/sec: 7.51909
10604 06:30:22.709965 140422082593664 basic_session_run_hooks.py:692] global_step/sec: 7.51909
INFO:tensorflow:loss = 2.0203084, step = 298129 (13.300 sec)

```

Gambar 12. Training dataset

Gambar 12 merupakan proses *training*. Semakin banyak perulangan maka akan semakin kecil nilai *loss* namun semakin lama juga waktu yang diperlukan untuk menunggu perhitungan selesai.



Gambar 13. Loss hasil training

Gambar 13 dapat dijelaskan bahwa dengan jumlah *iterasi* 300.000 steps/langkah maka nilai *loss* pada rata-rata *iterasi* yaitu sebesar 1.5. *Smoothed* dan *value* penjelasannya hampir sama yaitu mengambil nilai rata-rata dari *steps* sedangkan *steps* merupakan langkah-langkah dari *training*, *time* merupakan hasil terakhir dari *training* data dan *relative* merupakan keseluruhan hasil dari *training* data yang dilakukan (Rachman, Bethaningtyas, & Iskandar, 2021). Jadi Semakin grafik menurun maka nilai *loss* akan semakin baik yang menunjukkan semakin kecil kemungkinan kesalahan pada saat proses *training*. Jika grafik tidak terjadi perubahan ketika proses masih berjalan artinya sudah menunjukkan *konvergensi* pada proses *training*.



Gambar 14. Global step training

Gambar 14 dapat dijelaskan bahwa ketika proses *training* rata-rata waktu yang dibutuhkan secara *global* untuk melakukan setiap per stepsnya adalah selama 7.5 sec. Kenapa step globalnya 7.5 sec dikarenakan koneksi internet dan spesifikasi laptop yang stabil dan bagus, semakin bagus dan stabil sinyal internet dan spesifikasi laptop maka semakin cepat per stepsnya (Yinta, 2020).

4.4 Pengujian Model

Untuk melakukan pengujian pada model yang telah dihasilkan maka dilakukan proses mengevaluasi matriks model, pada penelitian ini menggunakan *Intersection over union (IoU)*, *Precision*, *Recall* and *mAP* sebagai matriks penting untuk evaluasi model. Berikut gambar beserta penjelasan dari masing-masing matriks:

1. *Intersection over union (IoU)*, *IoU* adalah selisih antara kebenaran dasar (*ground truth*) dan nilai prediksi (*predicted value*).

$$IoU = \frac{B \cap C}{B \cup C} \quad (1)$$

Pada rumus (1) dimana B adalah nilai kebenaran dasar suatu objek, dan C adalah nilai prediksi (Cartucho, 2016).



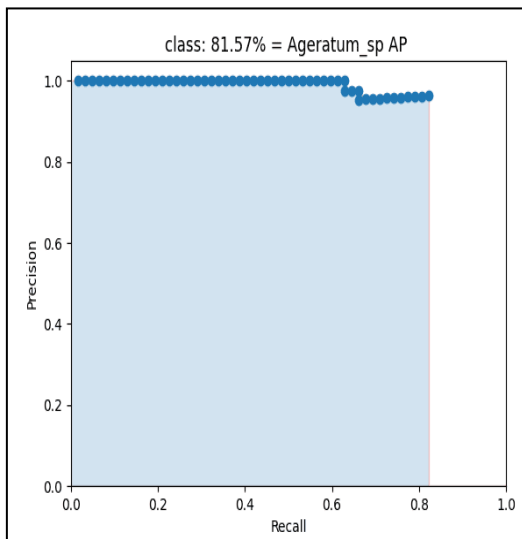
Gambar 15. IoU objek gulma *ageratum sp*

Gambar 15 merupakan hasil *Predicted* dan *Ground Truth* yang mana warna hijau merupakan *Predicted* dan warna biru merupakan *Ground Truth*. Gambar diatas merupakan salah satu dari hasil *Predicted* dan *Ground Truth* dari setiap jenis gulma.

2. *Precision dan Recall, Presisi (P) dan recall (R)* telah dihitung berdasarkan positif benar (TP) positif salah (FP) dan negatif palsu (FN). Presisi dan perolehan didefinisikan dalam persamaan berikut:

$$P = \frac{TP}{FP+TP} \text{ \& } R = \frac{TP}{FN+TP} \quad (2)$$


Pada rumus (2) TP adalah pendeteksian suatu objek secara benar dengan sampel positif, dan FP adalah pendeteksian suatu objek secara negatif oleh kesalahan sampel positif. FN tidak terdeteksi dari objek dengan sampel positif. *Precision-recall* adalah salah satu ukuran penting untuk mengevaluasi kinerja jaringan pada dataset pengujian. Selain itu, presisi diukur sehubungan dengan relevansi dalam hasil, sementara recall mengukur jumlah total hasil yang benar dan relevan. Kurva *presisi-recall* masing-masing dinyatakan dalam sumbu y dan sumbu x (Cartucho, 2016).



Gambar 16. P & R gulma *ageratum_sp*

Gambar 16 Merupakan nilai *precision* dan *recall* dari gulma *ageratum sp*. *Precision* dapat dilihat sebagai ukuran kualitas, dan *recall* sebagai ukuran kuantitas. *Precision* yang lebih tinggi berarti algoritma menghasilkan hasil yang lebih relevan daripada yang tidak relevan, dan *recall* yang tinggi berarti algoritma menghasilkan sebagian besar hasil yang relevan.

3. *Mean Average Precision (mAP)*, adalah rata-rata AP. Dalam beberapa konteks, peneliti menghitung AP untuk setiap kelas dan menghitung rata-ratanya (Cartucho, 2016). Tetapi dalam beberapa konteks, AP dan mAP memiliki arti yang sama.



Gambar 17. *mAP* seluruh kelas

Gambar 17 merupakan hasil dari semua jenis Gulma yang mana menunjukkan tiap *class* dari jenis gulma, dan mendapatkan hasil mAP seperti gambar diatas. dengan akurasi tertinggi adalah *Ageratum sp* dengan nilai akurasi **0,82** yaitu bilangan decimal apabila di persen kan menjadi **81.57%** dan akurasi terendah yaitu *Commelina sp* dengan nilai akurasi **0.35** yaitu bilangan decimal apabila di persen kan **34.72%**.

Tabel 1 Hasil akurasi dari model *Single Shot Detector*

Kelas	Jumlah data Training	Jumlah Data Testing	Confidence (threshold)	AP (perkelas)
<i>Ageratum sp.</i>	200	50	@0.8	81.57%
<i>Eleusine sp.</i>	200	32		72.00%
<i>Sacciolepis sp.</i>	200	35		61.47%
<i>Commelina sp.</i>	200	33		34.72%
mAP	800	150		62.44%

4.5 Hasil Deteksi

Hasil deteksi pada model ini dilakukan pada 4 kelas gulma yaitu *Ageratum sp.*, *Commelina sp.*, *Eleusine sp.* dan *Sacciolepis sp.* Untuk nilai *confidence* adalah @ 0.8. Menghasilkan mAP untuk semua kelas adalah **62.44**.

Pada tabel 1 kenapa Jumlah dataset validasi menjadi berkurang, ini dikarenakan data validasi untuk menghitung akurasi hanya menggunakan data citra yang memiliki objek kelas yang sama, sehingga akurasi yang dihasilkan adalah akurasi dari kelas tersebut. Namun jika dalam data citra tersebut bercampur banyak kelas objek. Maka akurasi per kelas akan semakin sulit untuk ditentukan. Dataset validasi dikurangi sesuai kondisi agar dapat menghitung akurasi per kelas. Karena pada dasarnya SSD hanya menghitung akurasi dari semua data tidak per kelas. penjelasan dari tiap gulma bisa dilihat dari penjelasan di bawah ini:

1. *Ageratum sp* memiliki akurasi yang paling tinggi diantara genus gulma lain yaitu **81.57%**. Karena *ageratum sp* sendiri memiliki ciri yang berbeda dari genus yang lain yaitu *Ageratum sp* merupakan gulma daun lebar.
2. *Eleusine sp* = **72.00%** juga memiliki akurasi tinggi dikarenakan *Eleusine sp* memiliki karakter daun yang Panjang dan kecil.
3. *Sacciolepis sp* = **61.47%** dan *Commelina sp.* = **34.72%** yang memiliki akurasi jauh lebih kecil dikarenakan karakteristik daun kedua gulma hampir sama dengan jagung, seperti bentuk daun yang pipih, Panjang dan lebar.

Hasil dari tabel 1 merupakan akurasi yang dihasilkan model, dengan akurasi tertinggi

adalah *Ageratum sp.* dengan nilai akurasi **81.57%** dan akurasi terendah yaitu *Commelina sp.* dengan nilai akurasi **34.72%**.

5. KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan analisis dan penelitian yang telah dilakukan, maka dapat diperoleh beberapa kesimpulan sebagai berikut:

1. Penelitian ini telah menerapkan *model Single Shot Detector (SSD)* untuk mengidentifikasi genus gulma yang berada pada tanaman budidaya jagung (*zea mays*) mampu mengidentifikasi 4 genus yaitu: yaitu *Ageratum sp.*, *Commelina sp.*, *Eleusine sp.* dan *Sacciolepis sp.*
2. Penelitian menghasilkan model baru yaitu hasil dari training data yang dapat digunakan untuk mengidentifikasi 4 genus gulma yaitu: *Ageratum sp.*, *Commelina sp.*, *Eleusine sp.* dan *Sacciolepis sp.*
3. Penelitian menghasilkan model *training* yang dievaluasi memiliki akurasi rata rata pada semua kelas sebesar **62.44%**. *Ageratum sp* memiliki akurasi yang paling tinggi diantara genus gulma lain yaitu **81.57%**. Karena *ageratum sp* sendiri memiliki ciri yang berbeda dari genus yang lain yaitu *Ageratum sp* merupakan gulma daun lebar. *Eleusine sp.* = **72.00%** juga memiliki akurasi tinggi dikarenakan *Eleusine sp* memiliki karakter daun yang Panjang dan kecil. *Sacciolepis sp* = **61.47%** dan *Commelina sp* = **34.72%** yang memiliki akurasi jauh lebih kecil dikarenakan karakteristik daun kedua gulma hampir sama dengan jagung, seperti bentuk daun yang pipih, Panjang dan lebar.

5.2. Saran

Berdasarkan analisis, perancangan model, implementasi, dan pengujian model, maka untuk kesempurnaan dari pemecahan masalah ini ada beberapa saran bagi peneliti dimasa depan yakni :

1. Dilakukan *training* atau penambahan *dataset* untuk gulma yang memiliki ciri yang hampir sama, sehingga dapat meningkatkan akurasi pada gulma tersebut.
2. Dapat dikembangkan untuk mengidentifikasi gulma yang lebih banyak agar dapat diimplementasikan terhadap tanaman budidaya yang lebih bervariasi karena model

DAFTAR PUSTAKA

- [1] A, B., Ashqar, M., S, B., Abu-Nasser, S, S., & Abu-Naser. (2019). Plant Seedlings Classification Using Deep Learning. *International Journal of Academic Information Systems Research (IJAIRS)*, III(1), 7-14.
- [2] Ahmad, & Junaedi. (2006). Ulasan perkembangan terkini kajian aleopat. *Biopendix*, 160-170.
- [3] Arisandi, R., Dharmono, & Muchyar. (2015). Keanekaragaman Spesies Familia Poaceae di Kawasan Reklamasi Tambang Batubara PT Adaro Indonesia Kabupaten Tabalong . *Seminar Nasional XII Pendidikan Biologi FKIP UNS* (hal. 733-739). Banjarmasin: Postgraduate Program Lambung Mangkurat University.
- [4] Bozkurt, E. (2019, 01 04). *Github*. (enginBozkurt) Dipetik 08 26, 2020, dari https://github.com/enginBozkurt/Object_Detection_With_SSD
- [5] Cartucho, J. (2016, january 29). *github*. Diambil kembali dari <https://github.com/Cartucho>: <https://github.com/Cartucho/mAP>
- [6] Hartono. (2009). Inventarisasi Jenis-Jenis Tumbuhan yang dapat Digunakan sebagai Bahan Praktikum Sistem Transportasi pada Tumbuhan. *Bionature*, 93 - 101.
- [7] Huang, J., Rathod, V., Sun, C., Zhu, M., Korattikara, A., Korattikara, A., . . . Murphy, K. (2017). Speed/Accuracy Trade-Offs for. *IEEE Conference on Computer Vision and Pattern*, II(2), 3296-3297.
- [8] Indra, K. (2017, 04 2). <https://www.teorieno.com/2017/04/klasifikasi-dan-morfologi-bandotan.html>. Diambil kembali dari [klasifikasi-dan-morfologi-bandotan](https://www.teorieno.com/2017/04/klasifikasi-dan-morfologi-bandotan.html): <https://www.teorieno.com/2017/04/klasifikasi-dan-morfologi-bandotan.html>
- [9] Izzuddin, A., & Wahyudi, M. R. (2020). Pengenalan Pola Daun untuk Membedakan Tanaman Padi dan Gulma Menggunakan Metode Principal Components Analysis (PCA) dan Extreme Learning Machine (ELM). *ALINIER*, 44-51.
- [10] Mas'ud, H. (2019). Komposisi dan Efisiensi. *J. Agroland*, 118-123.
- [11] Muhazzab, M. Z., Soetedjo, A., & Ashari, I. (2019). Rancang Bangun Robot Pembersih Tanaman Gulma Padi Otomatis. *Seminar Hasil Elektro S1 ITN Malang*, 7(1), 4-9.
- [12] Musriadi. (2014, 11 4). <https://bengkulu.antaranews.com/berita/27751/produksi-jagung-bengkulu-2014-turun-21002-ton>. Dipetik 08 20, 2020, dari <https://bengkulu.antaranews.com/berita/27751/produksi-jagung-bengkulu-2014-turun-21002-ton>
- [13] Rachman, F. F., Bethaningtyas, H., & Iskandar, R. F. (2021). Analisis Sistem Deteksi Penggunaan Hard Hat Pada Pekerja Konstruksi Menggunakan Metode Jaringan Syaraf Tiruan Konvulasi. *e-Proceeding of Engineering*, 237-333.
- [14] Razak, A. (2018). *Survey Rumput Belulang (Eleusine indica L.) Resisten Glifosat Pada Lahan Jagung Di Provinsi Sumatera Utara, Lampung Dan Naggroe Aceh Darussalam*. Medan: Universitas Sumatera Utara.
- [15] Saptasari, & Murni. (2012). Pembelajaran Berbasis Kontekstual Sebagai Upaya Peningkatan Minat Mahasiswa pada Taksonomi Tumbuhan. *Jurnal Pendidikan Dan Pembelajaran*, 200-201.
- [16] Sastroutomo, S. (1990). Ekologi gulma. *PT Gramedia Pustaka utama*, II(3), 557-558.
- [17] Sivakumar, A. N., Li, J., Stephen Scott, E. P., Jhala, A. J., Luck, J. D., & Shi, Y. (2020). Comparison of Object Detection and Patch-Based Classification Deep Learning Models on Mid- to Late-Season Weed Detection in UAV Imagery. *Remote Sens*, 1-22.
- [18] Tabri, A. F., & Fahdiana. (2017). Pengendalian Gulma pada Pertanaman Jagung. *Balai Penelitian Tanaman Serealia, Maros*, II(5), 235-238.
- [19] Thohar, A. N., & Adhitama, R. (2019). Deteksi Objek Secara Real-Time Untuk Wayang Punakawan. *Jurnal Infotel Informatika - Telekomunikasi - Elektronik*, 11(4), 126-127.

- [20] Yinta, N. M. (2020). *Implementasi Deep Learning Object Detection Rambu K3 Pada Video Menggunakan Metode Convilutional Neural Network (CNN) Dengan Tensorflow*. Yogyakarta: Universitas Islam Indonesia.